

Instituto Tecnológico y de Estudios Superiores de Monterrey

Escuela de Ingeniería y Ciencias

Campus Monterrey

TC3006C.102: Inteligencia artificial avanzada para la ciencia de datos I

**Análisis y Reporte sobre el desempeño del modelo. (Portafolio Análisis)**

Alumno:

Josué Emmanuel Flores Mendoza - A00833132

Profesores:

Jesús Adrián Rodríguez Rocha

Sábado 7 de septiembre de 2024

## Índice

<b>Introducción</b>	<b>3</b>
<b>Descripción del Conjunto de Datos</b>	<b>3</b>
<b>Elección de Features</b>	<b>5</b>
1. Edad (Age)	5
2. Sexo (Sex)	5
3. Presión arterial en reposo (Resting Blood Pressure)	6
4. Colesterol sérico (Serum Cholesterol)	7
5. Azúcar en sangre en ayunas (Fasting Blood Sugar)	7
6. Tipo de dolor en el pecho (Chest Pain Type)	8
7. Resultados electrocardiográficos en reposo (Resting ECG Results)	9
8. Frecuencia cardíaca máxima alcanzada (Maximum Heart Rate Achieved)	9
9. Angina inducida por ejercicio (Exercise-Induced Angina)	10
10. Depresión del segmento ST inducida por ejercicio (ST Depression Induced by Exercise)	10
11. Slope (Pendiente del segmento ST)	11
12. Ca (Número de vasos principales coloreados por fluoroscopia)	12
13. Thal (Talasemia)	12
<b>Separación y evaluación del modelo con un conjunto de prueba y un conjunto de validación (Train/Test/Validation)</b>	<b>13</b>
<b>Evaluación de la Regresión Logística sin ajustes</b>	<b>14</b>
<b>Diagnóstico y explicación el grado de bias o sesgo: bajo medio alto</b>	<b>15</b>
<b>Diagnóstico y explicación el grado de varianza: bajo medio alto</b>	<b>15</b>
<b>Diagnóstico y explicación el nivel de ajuste del modelo: underfitt, fitt, overfitt</b>	<b>16</b>
<b>Técnicas de regularización o ajuste de parámetros para mejorar el desempeño del modelo</b>	<b>17</b>
<b>Evaluación de la Regresión Logística con ajustes</b>	<b>18</b>
<b>Conclusión</b>	<b>20</b>

## Introducción

En este análisis, se construyó un modelo de regresión logística para predecir la presencia de enfermedades cardíacas utilizando un conjunto de datos que contiene varias características clínicas de pacientes. El objetivo principal fue evaluar el desempeño del modelo y realizar ajustes necesarios para mejorar su capacidad predictiva. El enfoque empleado incluyó la división de los datos en conjuntos de entrenamiento y prueba, así como el uso de validación cruzada (*cross-validation*) para optimizar los hiperparámetros del modelo y prevenir problemas de *overfitting* o *underfitting*.

## Descripción del Conjunto de Datos


El conjunto de datos utilizado contiene 303 observaciones con 14 variables, incluidas la variable objetivo (target), que indica la presencia de enfermedad cardíaca (1) o su ausencia (0) (Tabla 1). Las características utilizadas en el modelo incluyen los siguientes factores:

- **age:** Edad del paciente (en años)
- **sex:** Sexo del paciente (1 = masculino, 0 = femenino)
- **cp:** Tipo de dolor en el pecho (0 = angina típica, 1 = angina atípica, 2 = dolor no anginal, 3 = asintomático)
- **trestbps:** Presión arterial en reposo (en mm Hg al ingreso en el hospital)
- **chol:** Colesterol sérico en mg/dl
- **fbs:** Azúcar en sangre en ayunas > 120 mg/dl (1 = verdadero; 0 = falso)
- **restecg:** Resultados electrocardiográficos en reposo (0-2)
- **thalach:** Frecuencia cardíaca máxima alcanzada
- **exang:** Angina inducida por ejercicio (1 = sí; 0 = no)
- **oldpeak:** Depresión del ST inducida por ejercicio en comparación con el reposo
- **slope (Pendiente del segmento ST):** Representa la pendiente del segmento ST en el electrocardiograma (ECG) durante el ejercicio máximo. (0 = Pendiente ascendente (upsloping); 1 = Pendiente plana (flat); 2 = Pendiente descendente (downsloping))
- **ca:** Representa el número de vasos sanguíneos principales (entre 0 y 4) que se colorean al aplicar un tinte (fluoroscopia).
- **thal:** Representa la condición de talasemia observada. (1 = Normal; 2 = Defecto fijo (fixed defect) 3 = Defecto reversible (reversible defect))
- **target:** Si el paciente tiene una enfermedad cardíaca (1 = verdadero, 0 = falso)

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1	1
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2	1
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2	1
3	56	1	1	120	236	0	1	178	0	0.8	2	0	2	1
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2	1

*Tabla 1. Primeras 5 filas del conjunto de datos*

Se graficó la distribución del label para visualizar si se tenían la misma cantidad de datos (Figura 1) :



*Figura 1: Distribución de los datos de personas con enfermedad cardíaca*

Al ver que los datos se encontraban en cantidades similares se evita que el modelo pueda volverse sesgado hacia la clase mayoritaria.

## Elección de Features

Para determinar cuáles eran las features más importantes se graficó cada feature vs label, y se calculó la correlación:

### 1. Edad (Age)

- **Correlación:** Aunque la correlación es débil, la edad puede influir en la probabilidad de tener una enfermedad cardíaca debido a las actividades hechas por cada grupo de individuos.
- **Distribución:** La Figura 2 muestra picos diferentes entre las edades, lo cual puede significar una relación de acuerdo a la edad.

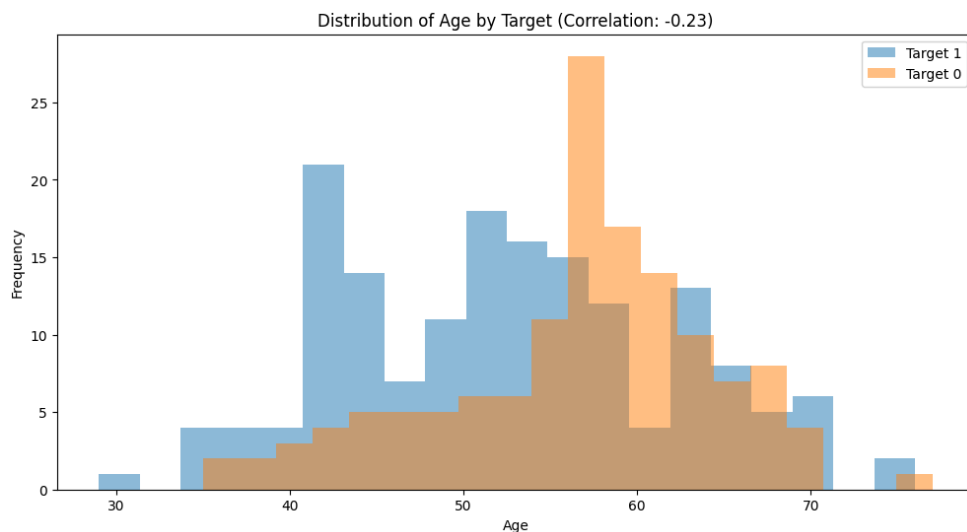


Figura 2: Distribución de edad por persona con enfermedad cardíaca

### 2. Sexo (Sex)

- **Correlación:** Aunque la correlación es débil, el sexo puede influir en la probabilidad de tener una enfermedad cardíaca debido a diferencias biológicas y hormonales entre hombres y mujeres.
- **Distribución:** La Figura 3 muestra diferencias en la proporción de hombres y mujeres entre los grupos con y sin enfermedad cardíaca, lo que sugiere que el sexo podría ser un factor relevante.

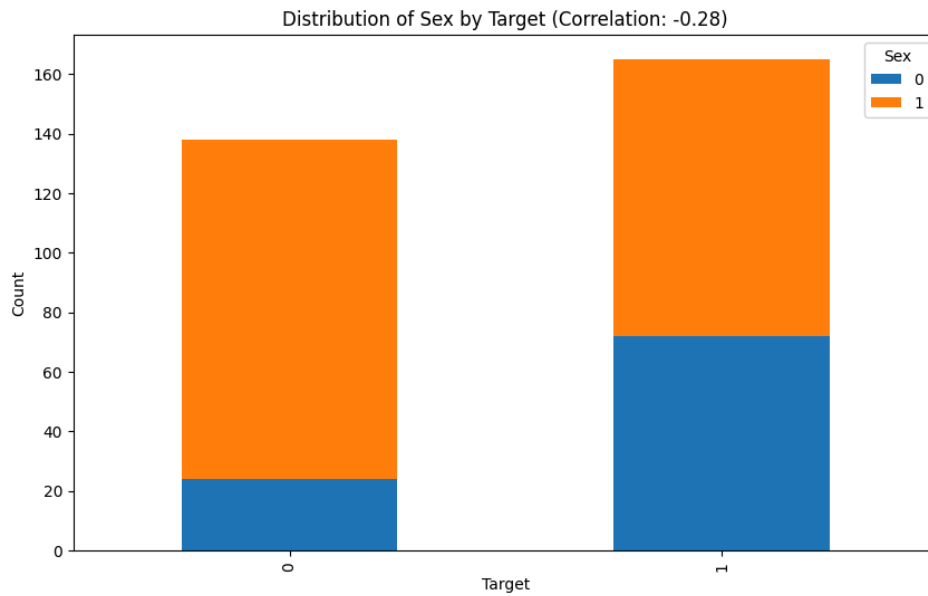


Figura 3: Distribución de sexo por persona con enfermedad cardíaca

### 3. Presión arterial en reposo (Resting Blood Pressure)

- **Correlación:** Muy débil (-0.14), indicando una relación negativa muy débil.
- **Distribución:** En la Figura 4 las distribuciones de la presión arterial en reposo para ambos targets son bastante similares, lo que refuerza la idea de que este feature no es un predictor significativo.

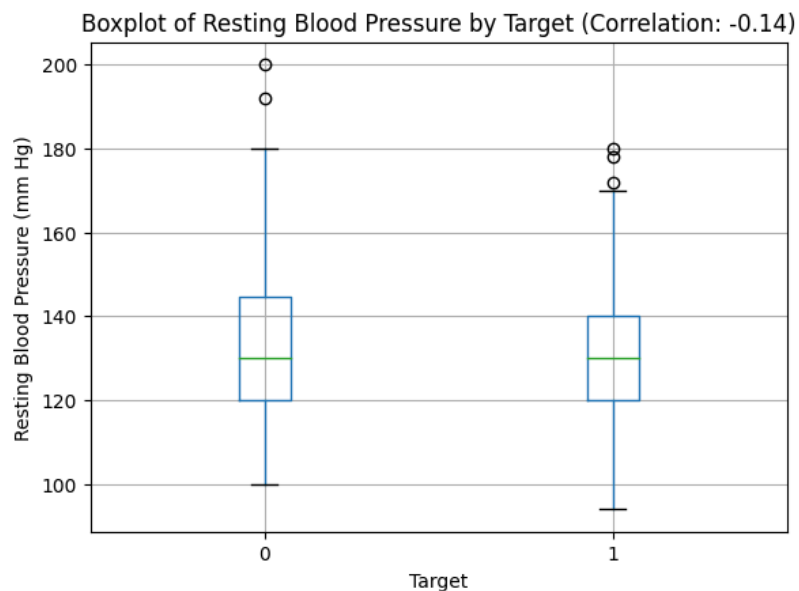


Figura 4: Boxplot de la presión en la sangre en reposo por target

#### 4. Colesterol sérico (Serum Cholesterol)

- **Correlación:** Muy débil (-0.09), indicando una relación negativa extremadamente débil.
- **Distribución:** En la Figura 5, las distribuciones de colesterol sérico para ambos targets son bastante similares, lo que refuerza la idea de que este feature no es un predictor significativo.




Figura 5: Boxplot de Colesterol Sérico por persona con enfermedad cardíaca

#### 5. Azúcar en sangre en ayunas (Fasting Blood Sugar)

- **Correlación:** Extremadamente débil (-0.03), indicando una relación negativa extremadamente débil.
- **Distribución:** En la Figura 6 las proporciones de azúcar en sangre en ayunas son similares en ambos grupos, lo que refuerza la idea de que este feature no es un predictor significativo.

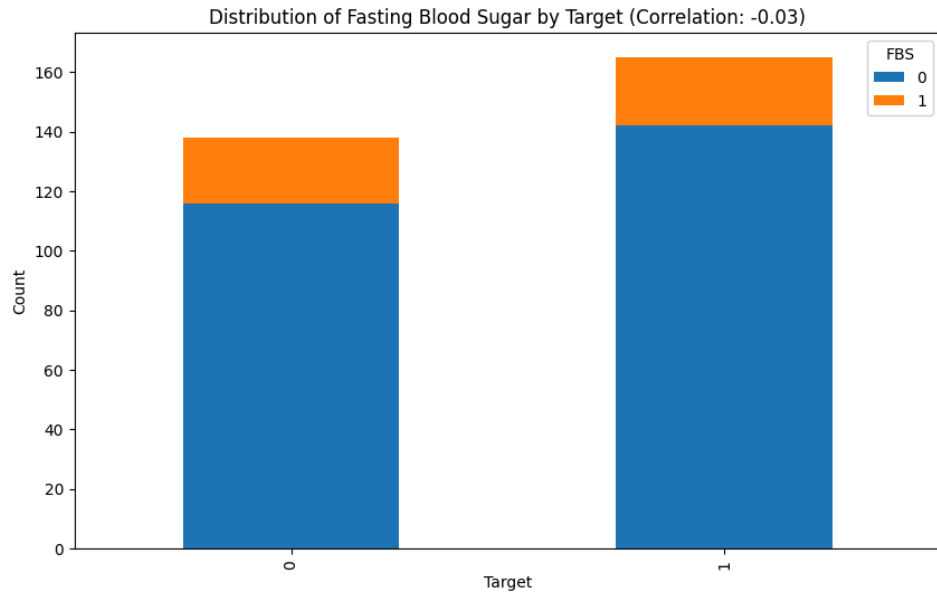


Figura 6: Distribución de azúcar en sangre en ayunas por persona con enfermedad cardíaca

## 6. Tipo de dolor en el pecho (Chest Pain Type)

- **Correlación:** La correlación es moderada (0.43), indicando una relación significativa.
- **Distribución:** La Figura 7 muestra que los tipos de dolor en el pecho varían considerablemente entre los grupos, lo que sugiere que ciertos tipos de dolor en el pecho están más asociados con la enfermedad cardíaca.




Figura 7: Tipo de dolor en el pecho por persona con enfermedad cardíaca



## 7. Resultados electrocardiográficos en reposo (Resting ECG Results)

- **Correlación:** La correlación es moderada (0.14), indicando una relación débil pero presente.
- **Distribución:** La Figura 8 muestra diferencias en los resultados electrocardiográficos entre los grupos, lo que sugiere que este feature podría ayudar a identificar la presencia de enfermedad cardíaca.

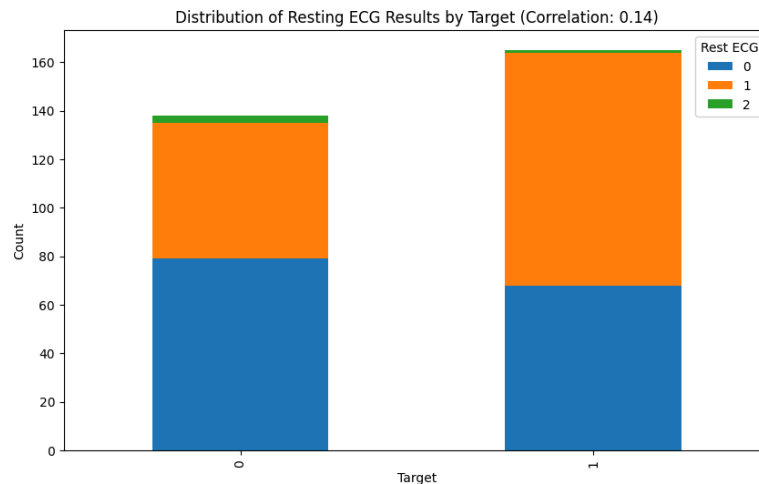


Figura 8: Distribución de electrocardiográficos por persona con enfermedad cardíaca

## 8. Frecuencia cardíaca máxima alcanzada (Maximum Heart Rate Achieved)

- **Correlación:** La correlación es moderada (0.42), indicando una relación significativa.
- **Distribución:** La Figura 9 muestra diferencias claras en la frecuencia cardíaca máxima alcanzada entre los grupos, lo que sugiere que este feature es un buen predictor de la enfermedad cardíaca.




Figura 9: Distribución de frecuencia cardíaca por persona con enfermedad cardíaca

## 9. Angina inducida por ejercicio (Exercise-Induced Angina)

- **Correlación:** La correlación es moderada (-0.44), indicando una relación significativa.
- **Distribución:** La Figura 10 muestra diferencias en la presencia de angina inducida por ejercicio entre los grupos, lo que sugiere que este feature es relevante para predecir la enfermedad cardíaca.

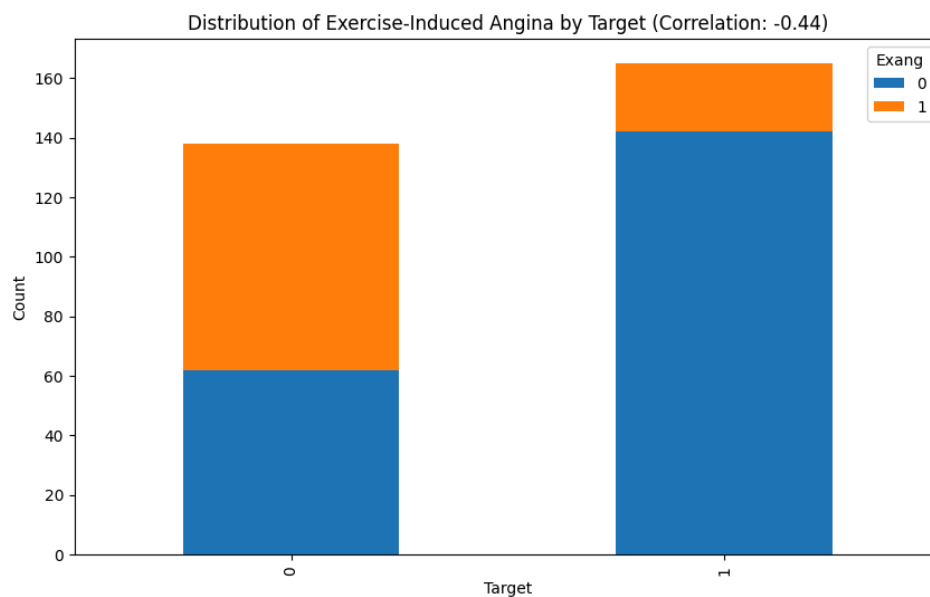


Figura 10: Distribución de Angina inducida por persona con enfermedad cardíaca

## 10. Depresión del segmento ST inducida por ejercicio (ST Depression Induced by Exercise)

- **Correlación:** La correlación es moderada (-0.43), indicando una relación significativa.
- **Distribución:** La gráfica muestra diferencias en la depresión del segmento ST entre los grupos, lo que sugiere que este feature es un buen predictor de la enfermedad cardíaca.

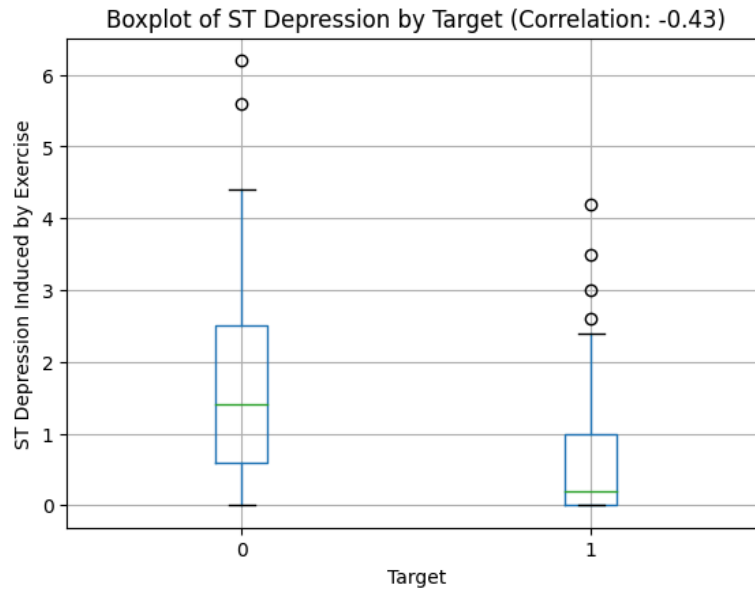


Figura 11: Boxplot de ST Inducida por persona con enfermedad cardíaca

### 11. Slope (Pendiente del segmento ST)

- **Correlación:** La correlación es moderada (0.35), indicando una relación significativa.
- **Distribución:** La gráfica muestra una clara inclinación a que los pacientes con pendiente descendente (downsloping) tienen problemas cardíacos.

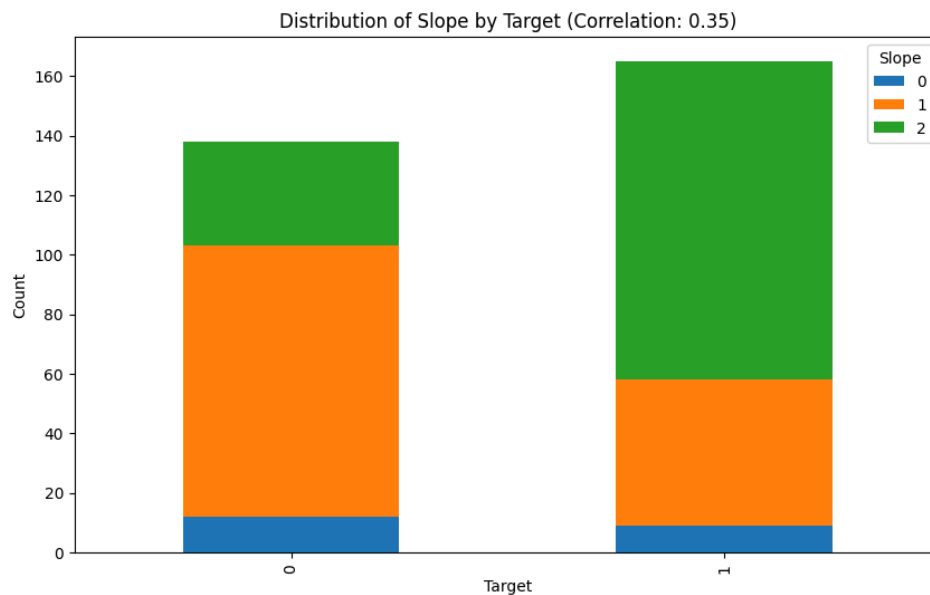


Figura 12: Pendiente del segmento ST por persona con enfermedad cardíaca

## 12. Ca (Número de vasos principales coloreados por fluoroscopia)

- **Correlación:** La correlación es moderada (-0.39), indicando una relación significativa.
- **Distribución:** La gráfica muestra una clara inclinación a que los pacientes con cero vasos principales coloreados tienen problemas cardíacos.

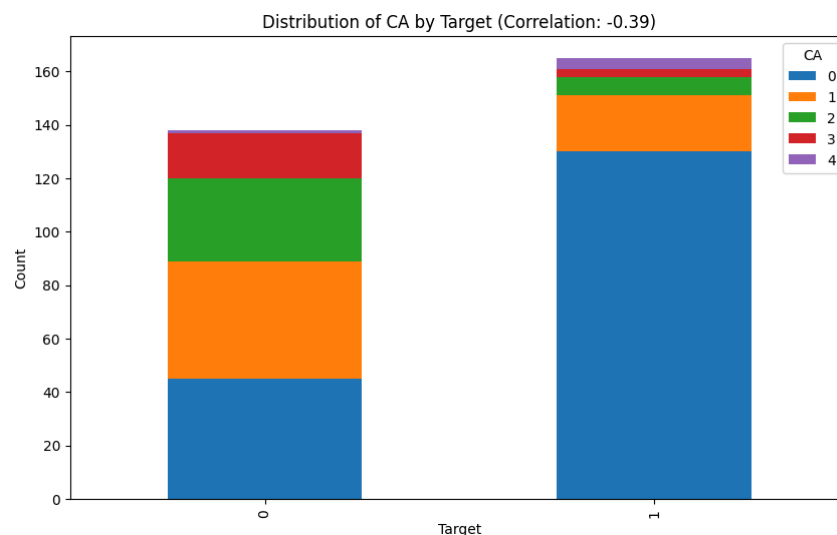


Figura 13: Distribución de vasos coloreados por persona con enfermedad cardíaca

## 13. Thal (Talasemia)

- **Correlación:** La correlación es moderada (-0.34), indicando una relación significativa.
- **Distribución:** La gráfica muestra una clara inclinación a que los pacientes con Talasemia tipo 2 tienen problemas cardíacos.

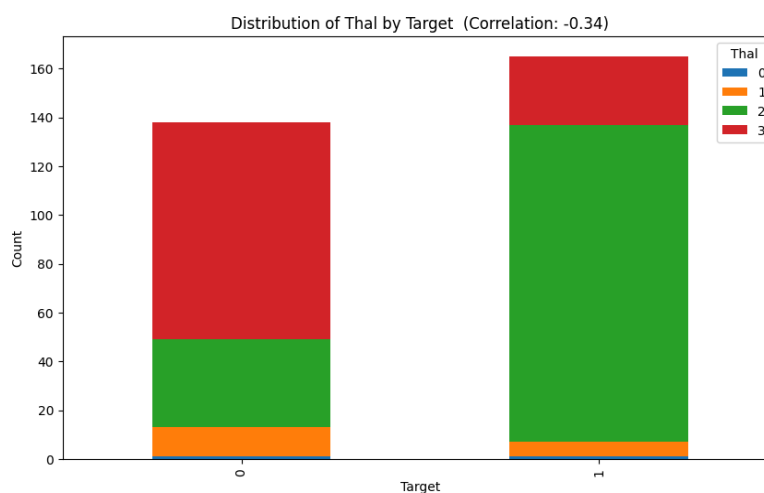


Figura 14: Distribución de Talasemia por persona con enfermedad cardíaca

En resumen, las features más relevantes y con las que se construyó el modelo son las siguientes:

- Sexo (Sex)
- Tipo de dolor en el pecho (Chest Pain Type)
- Resultados electrocardiográficos en reposo (Resting ECG Results)
- Frecuencia cardíaca máxima alcanzada (Maximum Heart Rate Achieved)
- Angina inducida por ejercicio (Exercise-Induced Angina)
- Depresión del segmento ST inducida por ejercicio (ST Depression Induced by Exercise)
- Slope (Pendiente del segmento ST)
- Ca (Número de vasos principales coloreados por fluoroscopia)
- Thal (Talasemia)

### **Separación y evaluación del modelo con un conjunto de prueba y un conjunto de validación (Train/Test/Validation)**

Para evaluar el rendimiento del modelo, se optó por dividir los datos en un conjunto de entrenamiento (75%) y un conjunto de prueba (25%). Esta estrategia permitió medir la capacidad del modelo para generalizar a nuevos datos no vistos previamente, garantizando que los resultados obtenidos fueran representativos del desempeño real del modelo.

En este caso, no se utilizó un conjunto de validación separado debido a que se implementó una técnica de validación cruzada con 10 particiones (10-fold cross-validation). La validación cruzada divide los datos en múltiples subconjuntos o "folds". En cada iteración, el modelo es entrenado en todos los folds menos uno, que se utiliza para validación. Este proceso se repite hasta que cada fold ha sido utilizado como conjunto de validación exactamente una vez. Al no reservar un conjunto de datos específicamente para validación, se maximiza la cantidad de datos disponibles para el entrenamiento del modelo. Esto es importante ya que el conjunto de datos no es tan grande y permite utilizar la mayor parte posible de la información para mejorar la capacidad de aprendizaje del modelo.

### Evaluación de la Regresión Logística sin ajustes

En la evaluación inicial del modelo de regresión logística sin ajustes, se obtuvo una exactitud de 0.87 en el conjunto de prueba. Esta métrica sugiere que el modelo es capaz de clasificar correctamente el 87% de los casos, lo cual es un buen punto de partida. Sin embargo, para entender mejor el desempeño del modelo, es crucial analizar otras métricas de evaluación, como la precisión, el recall y el F1-score para cada clase, así como observar la matriz de confusión

Exactitud en el conjunto de test: 0.87

Reporte de clasificación en el conjunto de test:

Clase	Precisión	Recall	F1-Score	Soporte
0	0.90	0.80	0.85	35
1	0.84	0.93	0.88	41
Accuracy			0.87	76
Macro Avg	0.87	0.86	0.87	76
Weighted Avg	0.87	0.87	0.87	76

Tabla 2: Reporte de la regresión Logística sin ajustes

Precisión (Precision): La precisión para la clase 0 (sin enfermedad cardíaca) es de 0.90, mientras que para la clase 1 (con enfermedad cardíaca) es de 0.84. Esto indica que, del total de predicciones que el modelo realizó para cada clase, un 90% y un 84% fueron correctas, respectivamente. Aunque la precisión es alta, existe una ligera inclinación hacia la clase 0, lo que podría indicar que el modelo tiene un pequeño sesgo hacia predecir la ausencia de la enfermedad.

Recall (Sensibilidad): El recall para la clase 0 es de 0.80, mientras que para la clase 1 es de 0.93. El valor más alto para la clase 1 sugiere que el modelo es muy efectivo para identificar los casos con enfermedad cardíaca, pero menos efectivo para identificar correctamente todos los casos sin la enfermedad. Este comportamiento puede ser deseable en un contexto clínico, donde es más importante minimizar los falsos negativos (no detectar una enfermedad existente) que los falsos positivos.

F1-Score: La métrica F1-score, que representa el balance entre precisión y recall, es de 0.85 para la clase 0 y 0.88 para la clase 1. Estos valores reflejan que, aunque el modelo tenga un buen rendimiento general, todavía hay un margen de mejora en la clasificación de ambas clases.

### **Diagnóstico y explicación el grado de bias o sesgo: bajo medio alto**

El modelo presenta un sesgo bajo, evidenciado por la alta precisión alcanzada tanto en el conjunto de entrenamiento como en el de prueba (87%). Este nivel de sesgo bajo sugiere que el modelo está capturando adecuadamente las relaciones subyacentes entre las variables sin simplificar excesivamente la complejidad del problema. Las curvas de aprendizaje (Figura 15) muestran que las tasas de error del entrenamiento y prueba son relativamente bajas y convergen a medida que aumenta el tamaño del conjunto de entrenamiento, lo que confirma que el modelo no está subestimando la complejidad del problema y está bien calibrado en términos de sesgo.

### **Diagnóstico y explicación el grado de varianza: bajo medio alto**

El grado de varianza del modelo es bajo, como se demuestra por la pequeña diferencia de precisión entre los conjuntos de entrenamiento y prueba. Esta baja varianza indica que el modelo tiene una buena capacidad de generalización a nuevos datos, evitando el sobreajuste (overfitting). La curva de aprendizaje (Figura 15) ilustra que el modelo mantiene una tasa de error constante y baja en ambos conjuntos a lo largo del entrenamiento. Esta tendencia muestra que el modelo no se está ajustando demasiado a las particularidades del conjunto de entrenamiento, sino que está aprendiendo patrones que son consistentes y aplicables a nuevos datos.




Figura 15: Curva de aprendizaje para el modelo de regresión logística

### Diagnóstico y explicación el nivel de ajuste del modelo: underfitt, fitt, overfitt

El modelo se encuentra bien ajustado (*fitting*). Esto se confirma por la alta precisión y consistencia de las métricas de evaluación (precisión, *recall* y *f1-score*) en ambos conjuntos. La matriz de confusión (Figura 16) también muestra un equilibrio adecuado entre falsos positivos y falsos negativos, reforzando que el modelo está correctamente ajustado.




Figura 16: Matriz de confusión de la regresión logística sin ajustes



La curva de aprendizaje presentada (Figura 15) revela que el modelo alcanza una alta precisión tanto en el conjunto de entrenamiento como en el conjunto de prueba. Sin embargo, las curvas convergen relativamente temprano, lo que sugiere que el modelo podría estar subutilizando su capacidad de aprendizaje debido a una posible falta de ajuste fino de los hiperparámetros. Esta observación sugiere la necesidad de ajustar el modelo para mejorar su capacidad predictiva.

### **Técnicas de regularización o ajuste de parámetros para mejorar el desempeño del modelo**

Para mejorar el desempeño del modelo, se emplearon técnicas de búsqueda en cuadrícula (*GridSearchCV*) para optimizar hiperparámetros como:

- C: Parámetro de regularización (0.01 fue el óptimo)
- solver: Algoritmo de optimización (liblinear)
- penalty: Tipo de penalización (l2)
- max\_iter: Número máximo de iteraciones (1000)

Se aplicó la regularización con penalización l2, que es una técnica que reduce la magnitud de los coeficientes del modelo, penalizando aquellos que son excesivamente grandes. Esta regularización ayuda a controlar la varianza del modelo, limitando la posibilidad de que el modelo se ajuste excesivamente a los datos de entrenamiento y reduciendo la sensibilidad del modelo a pequeñas fluctuaciones en los datos. Al aplicar la regularización l2, el modelo se volvió más robusto ante la variabilidad de los datos, logrando una mejora en la generalización sin incrementar significativamente el sesgo. Además, se utilizó la técnica de búsqueda en cuadrícula (*GridSearchCV*) para optimizar los hiperparámetros relacionados con la regularización, asegurando que se seleccionaran los valores más adecuados para el parámetro de regularización C, el tipo de penalización, y el algoritmo de optimización utilizado. Además, se implementó la técnica de *one-hot encoding* para mejorar el desempeño del modelo. Esta técnica permite convertir variables categóricas en una forma binaria que el modelo puede manejar más eficientemente, lo cual contribuyó a una mejora en la precisión y el rendimiento general del modelo.

Las características que se utilizaron con one-hot-encoding fueron las siguientes:

- Sex: Debido a que este dato es para identificar el sexo de los pacientes, es buena práctica haber separado entre hombres y mujeres con esta técnica:
- Slope: Como los datos de Slope identificaban la tendencia de la pendiente, tuve que aplicar esta técnica para que fuera más fácil de leer por el modelo.
- Thal: Es una variable categórica que determina el tipo de Talasemia, tuve que implementar esta técnica ya que no tenía valores en cero y solamente puse los datos que había.

A pesar de que también se podía aplicar para el tipo de dolor en el pecho, descubrí que estos datos no estaban muy bien distribuidos y se encontraban en mayor cantidad unos que otros, por lo que decidí dejar la feature como estaba ya que de otra manera solo confundía al modelo.

### Evaluación de la Regresión Logística con ajustes

Después de ajustar el modelo mediante técnicas de regularización y optimización de hiperparámetros con GridSearchCV, se observó una mejora notable en el rendimiento del modelo. Los mejores hiperparámetros encontrados fueron: {'C': 0.1, 'max\_iter': 100, 'penalty': 'l2', 'solver': 'saga'}. Estos ajustes resultaron en una ligera mejora en la exactitud del modelo, que pasó de 0.87 a 0.88 en el conjunto de prueba.

### Exactitud en el conjunto de test: 0.88

Clase	Precisión	Recall	F1-Score	Soporte
0	0.91	0.83	0.87	35
1	0.86	0.93	0.89	41
Accuracy			0.88	76
Macro Avg	0.88	0.88	0.88	76
Weighted Avg	0.88	0.88	0.88	76

Tabla 3: Reporte de regresión logística con ajustes.

**Precisión (Precision):** La precisión mejoró para ambas clases, alcanzando 0.91 para la clase 0 y 0.86 para la clase 1. Esta mejora en la precisión sugiere que, después de los ajustes, el modelo es más eficiente para identificar correctamente tanto a los pacientes con enfermedad cardíaca como a los que no la tienen, reduciendo los falsos positivos.

**Recall (Sensibilidad):** El recall para la clase 0 subió a 0.83, mientras que para la clase 1 se mantuvo en 0.93. Esta mejora para la clase 0 indica que el modelo es ahora más efectivo para identificar correctamente los casos sin enfermedad, reduciendo los falsos negativos.

**F1-Score:** El F1-score aumentó a 0.87 para la clase 0 y a 0.89 para la clase 1, lo que demuestra una mejora en el equilibrio entre precisión y recall en ambas clases. Esto sugiere que los ajustes realizados mejoraron la capacidad del modelo para realizar predicciones más consistentes y balanceadas entre las dos clases.




Figura 17: Curva de aprendizaje con ajustes

La curva de aprendizaje ajustada (Figura 17) muestra una menor brecha entre las tasas de error de entrenamiento y prueba en comparación con la curva original (Figura 15). Este comportamiento sugiere que el modelo con regularización  $l_2$  tiene una mejor capacidad de generalización y es menos propenso al sobreajuste (overfitting), debido a que penaliza los coeficientes más grandes y controla la complejidad del modelo. La aplicación de la regularización  $l_2$  ha sido clave para mejorar el desempeño del modelo. Al penalizar los

coeficientes grandes, esta técnica reduce la varianza del modelo sin incrementar significativamente el sesgo, permitiendo que el modelo se ajuste de manera más robusta a los datos sin sobreajustarse a los patrones de ruido. Esto ha permitido una mejora en la precisión general del modelo y una mayor confiabilidad en sus predicciones.




Figura 18: Matriz de confusión con ajustes.

## Conclusión

El desarrollo de este modelo de regresión logística para predecir la presencia de enfermedades cardíacas ha sido exitoso gracias a que se consideró tanto la optimización de los hiperparámetros como la adecuada selección de características relevantes. Durante el análisis, se identificó y mitigó adecuadamente el sesgo (bias) y la varianza del modelo, logrando un equilibrio óptimo entre la capacidad de predicción y la generalización a nuevos datos.

El uso de técnicas de validación cruzada permitió una evaluación precisa del modelo, asegurando que no se sobreajustara a los datos de entrenamiento, y manteniendo un nivel adecuado de varianza. La baja diferencia en la precisión entre los conjuntos de entrenamiento y prueba es evidencia de que el modelo generaliza bien y es capaz de ofrecer predicciones confiables en datos no vistos. Asimismo, la implementación de la regularización l2 y la

optimización de los hiperparámetros mediante GridSearchCV demostraron ser efectivas para mejorar el desempeño del modelo, reduciendo su varianza y aumentando su robustez.

Los resultados muestran que el modelo no solo alcanza altos niveles de precisión y recall, sino que también ofrece un rendimiento balanceado entre las distintas métricas de evaluación, como lo demuestra la matriz de confusión ajustada. Este balance es crucial en un contexto clínico, donde tanto los falsos positivos como los falsos negativos tienen implicaciones significativas para la salud del paciente.

Este proceso de modelado ha permitido consolidar habilidades importantes, como la capacidad de seleccionar y aplicar técnicas avanzadas de optimización de modelos, interpretar resultados y tomar decisiones basadas en datos para mejorar el rendimiento del modelo. Además, refuerza la importancia de comprender y manejar el sesgo y la varianza, elementos clave para asegurar que un modelo de aprendizaje automático no solo sea preciso, sino también fiable y aplicable en la práctica.

En general, la combinación de técnicas estadísticas robustas, estrategias de validación rigurosas y el uso adecuado de herramientas de regularización ha resultado en un modelo sólido que podría ser implementado en escenarios reales para apoyar decisiones clínicas, ofreciendo así un valor significativo en la predicción de enfermedades cardíacas.